Петрозаводский государственный университет Институт математики и информационных технологий Кафедра Информатики и математического обеспечения

Отчет о прохождении производственной практики

ГЕНЕРАЦИЯ ТЕКСТА С ИСПОЛЬЗОВАНИЕМ МАРКОВСКОЙ МОДЕЛИ И СТАТИСТИКИ ПРЕФИКСОВ

ыполнил студент 2 курса группы 22207: ордеев Никита Владиславович				
Гаправление подготовки бакалавриата: 9.03.04 Программная инженерия				
Место прохождения практики: Институт математики и информационных технологий				
Период прохождения практики: 29.05.22-09.06.23				
Руководитель: Богоявленская Ольга Юрьевна, к.т.н, доцент				
Оценка:				
	оценка			
Дата:				
-	∂ama			

Содержание

Bı	Введение				
1	Изу	чение литературы	4		
	1.1	Цепи Маркова	4		
2	Раз	работка программы	5		
	2.1	Функция проверки грамматики и улучшения структуры текста	5		
	2.2	Пользовательский интерфейс	6		
3 Тестирование программы					
	3.1	Время выполнения	10		
За	клю	чение	12		
Cı	писо	к литературы	13		
Π_{1}	рило	жение	14		
	.1	Код программы с добавленными функциями грамматической правильности			
		и связности сгенерированного текста	14		
	.2	Кол программы с пользовательским интерфейсом	16		

Введение

Актуальность исследования.

Цепи Маркова актуальны в математике, экономике, биологии, физике, компьютерных науках и медицине. Они используются для анализа временных процессов и прогнозирования состояний системы. В экономике определяются оптимальные стратегии и планирование бизнеса. В медицине моделируют заболевания, оценивают эффективность лечения. В генетике изучают эволюцию генов. В компьютерных науках разрабатывают алгоритмы машинного обучения и распознавания образов. Цепи Маркова широко применяются в анализе сложных процессов и предсказании будущих событий.

Цель данной работы: Генерация текста с использованием марковской модели и статистики префиксов.

Задачи данной работы:

- 1. Изучение теории, посвященной цепям Маркова;
- 2. Разработка программного кода для реализации алгоритма генерации текстов.

Методы, способы достижения поставленных целей и задач:

- 1. Анализ научной литературы и интернет-источников;
- 2. Проведения экспериментов, анализ их результатов.

1 Изучение литературы

1.1 Цепи Маркова

Цепи Маркова предоставляют уникальный метод генерации случайных текстов на основе статистической модели, оценивающей частоты букв, слов и словосочетаний в референсном тексте. Основная идея состоит в том, что частота различных словосочетаний может быть использована для создания текста, обладающего схожими статистическими свойствами.

Метод основан на использовании перекрывающихся словосочетаний исходного текста для определения вероятности следующего слова-суффикса для данного префикса из двух слов. Вначале алгоритм выбирает два первых слова текста и выводит их. Затем в цикле для текущего префикса случайно выбирается следующий суффикс на основе статистики исходного текста.

Следующий пример демонстрирует результаты генерации случайного текста с использованием предложенного подхода.

Show your flowcharts and tables and be mystified. Show your flowcharts will be obvious.

Такой текст более структурирован и осмыслен по сравнению с методами, где слова или буквы генерируются независимо друг от друга или на основе их абсолютной частоты в алфавите.

2 Разработка программы

Роли в команде

Наш сегмент проекта основывается на результатах труда коллег. Для успешной реализации проекта, задачи были распределены между членами команды.




Рис. 1 – Сегменты проекта

Укпере Вильямс	Гордеев Никита	Данило Пётр
1) Реализация базового	1) Добавление функций	1) Реализация решения с
решения программы	для проверки граммати-	использованием
генерации случайного	ческой правильности и	рекуррентной нейронной
текста с использованием	улучшения связности сге-	сети для генерации
алгоритма цепи Маркова	нерированного текста	текста
	2) Разработка пользова-	
	тельского интерфейса	

Таблица 1 – Распределение задач

2.1 Функция проверки грамматики и улучшения структуры текста

Для проверки грамматики и улучшения структуры текста можно использовать API LanguageTool[4]. Это библиотека с открытым исходным кодом, предназначенная для проверки грамматической правильности текста.

Основные возможности API LanguageTool:

- Поддержка множества языков: LanguageTool поддерживает более 20 языков, включая английский, русский, французский, немецкий и испанский.
- Несколько типов проверки: LanguageTool может проверять грамматику, орфографию, стиль и другие аспекты текста.
- Расширяемость: пользователи могут создавать собственные правила проверки и добавлять новые функции.

Чтобы начать использовать LanguageTool API, необходимо сначала установить его:

```
pip install language_tool_python
```

Теперь добавим функцию для обработки и коррекции сгенерированного текста. Она принимает текст на вход и пытается исправить его, используя "en-US" (американский английский) словарь LanguageTool. После этого она возвращает исправленный текст:

```
import language_tool_python

def grammar_and_style_check(text):
    tool = language_tool_python.LanguageTool('en-US')
    matches = tool.check(text)
    corrected_text = language_tool_python.utils.correct(text, matches)
    return corrected_text
```

Чтобы применить эту функцию к сгенерированному тексту, вызовем её, прежде чем сохранить текст в файл:

```
1 ...
2 generated_text = generate_text(prefix_stats, initial_prefix, text_length)
3 corrected_text = grammar_and_style_check(generated_text)
4
5 with open(answer_filepath, 'w') as f:
6 f.write(corrected_text)
7 ...
```

LanguageTool не гарантирует идеальную грамматику или стиль в сгенерированном тексте, но помогает улучшить его качество.

Полный текст программы находится в Приложении .1.

2.2 Пользовательский интерфейс

Будем создавать графический интерфейс, в котором по нажатию на кнопку "генерировать" новый сгенерированный текст сохраняется в файл answer.txt и одновременно этот же новый тексты выводится в графическом интерфейсе в многострочном окне.

Для создания графического интерфейса, будем использовать библиотеку Tkinter. В ней есть виджеты для создания кнопок и многострочных окон. Выполним следующие шаги:

Импоруем библиотеку Tkinter:

```
import tkinter as tk
```

Создадим главное окно:

```
1 root = tk.Tk()
```

Создадим многострочное текстовое поле:

```
1 answer_text = tk.Text(root, wrap="word", font=("Consolas", 10))
```

Создадим полосу прокрутки:

```
scrollbar = tk.Scrollbar(root, command=answer_text.yview)
```

Назначим полосу прокрутки текстовому полю:

```
1 answer_text.config(yscrollcommand=scrollbar.set)
```

Создадим кнопку для генерации и сохранения текста:

```
generate_button = tk.Button(root, text="Generate", command=generate_and_save_text)
```

Создадим функцию для генерации и сохранения текста в файл и отображения сгенерированного текста на экране:

```
def generate_and_save_text():
    corpus = load_text_from_file(source_filepath)

cleaned_text = preprocess_text(corpus)

prefix_stats = build_prefix_stats(cleaned_text, prefix_length)

initial_prefix_lc = initial_prefix_lower()

generated_text = generate_text(prefix_stats, initial_prefix_lc, text_length)

corrected_text = grammar_and_style_check(generated_text)

with open(answer_filepath, 'w') as f:

f.write(corrected_text)

answer_text.delete("1.0", tk.END)

answer_text.insert("1.0", generated_text)
```

Сделаем поле ввода параметров генерации текста и передачи значений в соответствующие переменные:

```
def update_parameters():
    global prefix_length, initial_prefix, text_length, source_filepath

prefix_length = int(prefix_length_entry.get())
initial_prefix = initial_prefix_entry.get()
```

```
text_length = int(text_length_entry.get())
           source_filepath = source_filepath_entry.get()
          prefix_length_label.config(text=f"Prefix Length: {prefix_length}")
           initial_prefix_label.config(text=f"Initial Prefix: {initial_prefix}")
           text_length_label.config(text=f"Text Length: {text_length}")
11
           source_filepath_label.config(text=f"Source File: {source_filepath}")
  prefix_length_entry = tk.Entry(parameters_frame, width=5)
15 prefix_length_entry.insert(tk.END, str(prefix_length))
16 prefix_length_entry.pack(anchor=tk.W, padx=5, pady=5)
  prefix_length_entry.bind("<FocusOut>", lambda event: update_parameters())
initial_prefix_entry = tk.Entry(parameters_frame, width=20)
20 initial_prefix_entry.insert(tk.END, initial_prefix)
21 initial_prefix_entry.pack(anchor=tk.W, padx=5, pady=5)
22 initial_prefix_entry.bind("<FocusOut>", lambda event: update_parameters())
24 text_length_entry = tk.Entry(parameters_frame, width=5)
25 text_length_entry.insert(tk.END, str(text_length))
26 text_length_entry.pack(anchor=tk.W, padx=5, pady=5)
27 text_length_entry.bind("<FocusOut>", lambda event: update_parameters())
  source_filepath_entry = tk.Entry(parameters_frame, width=20)
30 source_filepath_entry.insert(tk.END, source_filepath)
31 source_filepath_entry.pack(anchor=tk.W, padx=5, pady=5)
32 source_filepath_entry.bind("<FocusOut>", lambda event: update_parameters())
```


Разместим все элементы в нужном порядке:

```
answer_text.pack(expand=True, fill="both")
scrollbar.pack(side=tk.RIGHT, fill=tk.Y)
generate_button.pack(pady=10)
```


Запустим бесконечное повторение программы:

```
root.mainloop()
```


В итоге, получается программа, которая генерирует текст на основе заданных параметров, отображает его в многострочном текстовом поле и сохраняет его в файл при нажатии на кнопку "Generate". Полный текст программы находится в Приложении .2.



(а) Приветственный экран



(b) Генерация с параметрами: "1", "because", "1000", "source.txt"



(c) Генерация с параметрами: "1", "my", "100", "source.txt"

Рис. 2 – Экраны приложения

3 Тестирование программы

3.1 Время выполнения

Для того, чтобы программа печатала время выполнения, воспользуемся модулем time. Добавим в код строки:

```
import time
start_time = time.time()

# тут идут все основные функции и вызовы

end_time = time.time()
print(end_time - start_time)
```

Таким образом, при завершении программы в консоль будет выведено время, затраченное на ее выполнение.

Запуск	Программа без функции про-	Программа с функцией про-
	верки грамматики	верки грамматики
1	0.0009577274322509766	7.03693962097168
2	0.003083467483520508	7.452900648117065
3	0.0038442611694335938	8.426994562149048
4	0.004538059234619141	10.353859424591064
5	0.0029518604278564453	10.223316669464111
6	0.0027184486389160156	10.636064767837524
7	0.0022034645080566406	12.667102098464966
8	0.0026845932006835938	13.87061095237732
9	0.0019922256469726562	12.87858390808105
10	0.0023589134216308594	14.952302932739258

Таблица 2 – Время затраченное на ее выполнение программ

Несмотря на то, что функция проверки грамматики замедляет работу программы, использование такой функции позволяет генерировать более грамотный текст, без ошибок и несогласования в частях речи. Это важно, если требуется использовать результаты программы в каких-то серьезных целях, например, в автоматическом создании текстов для сайтов, каталогов или других документов. Поэтому, если важна грамотность генерируемого текста, необходимо принимать в расчет возможное замедление работы программы и использовать функцию проверки грамматики. Кроме того, можно искать способы для

оптимизации работы программы, например, уменьшения количества проверяемых вариантов, чтобы достичь более быстрой работы, не ухудшая качество генерируемого текста.

Заключение

В процессе производственной практики была создана программу для генерации текста на естественном языке с использованием цепей Маркова. Я изучил основные принципы работы с такой цепью, а также написал код с помощью языка Python для реализации генерации текста.

Список литературы

- 1. Керниган Б., Пайк Р. Практика программирования. 8-е изд. М., СПб., Киев: Издательский дом "Вильямс 2015. 288 с.
- 2. Использование Марковских цепей при решении различных прикладных задач // Научный журнал Фундаментальные исследования URL: https://fundamental-research.ru/ru/article/view?id=1686
- 3. Краткое введение в цепи Маркова // Xабр URL: https://habr.com/ru/articles/455762/
- 4. language-tool-python 2.7.1 // PyPI URL: https://pypi.org/project/language-tool-python/
- 6. Разметка виджетов в Tkinter pack, grid и place // Python 3 URL: https://python-scripts.com/tkinter-layout-example
- 7. Изучаем lambda-функции в Python // Python 3 URL: https://python-scripts.com/lambda

Приложение

.1 Код программы с добавленными функциями грамматической правильности и связности сгенерированного текста

```
1 # Импортируем необходимые библиотеки
2 import string
3 import random
4 import language_tool_python
5 import time
    Функция проверки текста на грамматику и стиль
  def grammar_and_style_check(text):
       # Создаем объект класса LanguageTool на английском языке
       tool = language_tool_python.LanguageTool('en-US')
       # Получаем список найденных ошибок и предлагаемых исправлений
      matches = tool.check(text)
      # Исправляем найденные ошибки в тексте
       corrected_text = language_tool_python.utils.correct(text, matches)
14
       return corrected_text
17 # Загрузка текста из файла
18 def load_text_from_file(filepath):
       with open(filepath) as f:
          corpus = f.read()
       return corpus
  # Предварительная обработка текста
  def preprocess_text(text):
       # Приводим текст к нижнему регистру
       cleaned_text = text.lower()
26
       # Удаляем всю пунктуацию из текста
       cleaned_text = cleaned_text.translate(str.maketrans("", "", string.punctuation))
       # Заменяем символ новой строки на пробел
       cleaned_text = cleaned_text.replace("\n", " ")
30
       # Удаляем лишние пробелы, объединяя слова в тексте
       cleaned_text = " ".join(cleaned_text.split())
       return cleaned_text
33
2.4
    Построение статистики по префиксам
  def build_prefix_stats(text, prefix_length):
       prefix_stats = {}
       words = text.split()
       # Проходим по всем словам в тексте
       for i in range(len(words) - prefix_length):
41
           prefix = tuple(words[i : i + prefix_length])
           suffix = words[i + prefix_length]
43
           # Заполняем словарь статистикой по префиксам и соответствующим им суффиксам
```

```
45
           prefix_stats.setdefault(prefix, []).append(suffix)
46
47
       return prefix_stats
48
    Генерация текста на основе статистики по префиксам
50 def generate_text(prefix_stats, initial_prefix, length):
       current_prefix = tuple(initial_prefix.split())
       generated_text = list(current_prefix)
       # Генерируем текст, пока не достигнем заданной длины или не будет найдена последовательность без
54
       соответствующих суффиксов
       while len(generated_text) < length:</pre>
           if current_prefix not in prefix_stats or not prefix_stats[current_prefix]:
56
               break
57
58
           next_word = random.choice(prefix_stats[current_prefix])
           generated_text.append(next_word)
60
           current_prefix = tuple(generated_text[-len(current_prefix) :])
61
62
63
       return " ".join(generated_text)
65 # Основная функция программы
66 def main():
       # Пути к файлам с исходным и результативным текстом
       source_filepath = "source.txt"
       answer_filepath = "answer.txt"
70
       # Настройки для генерации текста
      prefix_length = 1
72
       initial_prefix = "because"
73
       text_length = 1000
74
75
       # Загружаем текст из файла
76
       corpus = load_text_from_file(source_filepath)
       # Предварительно обрабатываем текст
79
       cleaned_text = preprocess_text(corpus)
81
       # Строим статистику по префиксам
       prefix_stats = build_prefix_stats(cleaned_text, prefix_length)
       # Приводим начальный префикс к нижнему регистру
83
       initial_prefix = initial_prefix.lower()
       # Генерируем текст на основе полученной статистики по префиксам
       generated_text = generate_text(prefix_stats, initial_prefix, text_length)
86
87
       # Проверяем генерированный текст на грамматику и стиль
88
       corrected_text = grammar_and_style_check(generated_text)
89
90
       # Записываем результативный текст в файл
91
       with open(answer_filepath, 'w') as f:
92
           f.write(corrected_text)
93
94
```

```
95 # Запуск программы
96 if __name__ == "__main__":
97 main()
```

.2 Код программы с пользовательским интерфейсом

```
1 # Импортируем необходимые библиотеки
2 import string
3 import random
4 import tkinter as tk
5 from tkinter import ttk
6 import language_tool_python
    Функция проверки текста на грамматику и стиль
9 def grammar_and_style_check(text):
       # Создаем объект класса LanguageTool на английском языке
       tool = language_tool_python.LanguageTool('en-US')
       # Получаем список найденных ошибок и предлагаемых исправлений
      matches = tool.check(text)
       # Исправляем найденные ошибки в тексте
14
       corrected_text = language_tool_python.utils.correct(text, matches)
       return corrected_text
16
    Загрузка текста из файла
  def load_text_from_file(filepath):
       with open(filepath) as f:
20
          corpus = f.read()
21
22
       return corpus
24 # Предварительная обработка текста
  def preprocess_text(text):
       # Приводим текст к нижнему регистру
       cleaned_text = text.lower()
       # Удаляем всю пунктуацию из текста
28
       cleaned_text = cleaned_text.translate(str.maketrans("", "", string.punctuation))
       # Заменяем символ новой строки на пробел
30
       cleaned_text = cleaned_text.replace("\n", " ")
31
       # Удаляем лишние пробелы, объединяя слова в тексте
32
       cleaned_text = " ".join(cleaned_text.split())
33
       return cleaned_text
34
35
    Построение статистики по префиксам
  def build_prefix_stats(text, prefix_length):
       prefix_stats = {}
       words = text.split()
41
       # Проходим по всем словам в тексте
       for i in range(len(words) - prefix_length):
          prefix = tuple(words[i : i + prefix_length])
43
```

```
suffix = words[i + prefix_length]
44
45
           # Заполняем словарь статистикой по префиксам и соответствующим им суффиксам
           prefix_stats.setdefault(prefix, []).append(suffix)
46
47
       return prefix_stats
  # Генерация текста на основе статистики по префиксам
  def generate_text(prefix_stats, initial_prefix, length):
       current_prefix = tuple(initial_prefix.split())
       generated_text = list(current_prefix)
53
54
       # Генерируем текст, пока не достигнем заданной длины или не будет найдена последовательность без
       соответствующих суффиксов
       while len(generated_text) < length:</pre>
56
           if current_prefix not in prefix_stats or not prefix_stats[current_prefix]:
               break
58
59
           next_word = random.choice(prefix_stats[current_prefix])
60
61
           generated_text.append(next_word)
           current_prefix = tuple(generated_text[-len(current_prefix) :])
62
63
       return " ".join(generated_text)
64
    Функция для создания графического интерфейса пользователя.
67 def create_gui():
       # Создаем основное окно приложения.
       root = tk.Tk()
69
       # Создаем фрейм для настройки параметров генерации.
71
       parameters_frame = tk.Frame(root)
      parameters_frame.pack(side=tk.LEFT)
74
       # Создаем метки для отображения текущих значений параметров.
75
       prefix_length_label = tk.Label(parameters_frame, text=f"Prefix Length: {prefix_length}")
76
       prefix_length_label.pack()
78
       initial_prefix_label = tk.Label(parameters_frame, text=f"Initial Prefix: {initial_prefix}")
79
80
       initial_prefix_label.pack()
       text_length_label = tk.Label(parameters_frame, text=f"Text Length: {text_length}")
82
       text_length_label.pack()
84
       source_filepath_label = tk.Label(parameters_frame, text=f"Source File: {source_filepath}")
85
       source_filepath_label.pack()
86
87
       # Создаем кнопку для запуска генерации текста.
88
       generate_button = tk.Button(parameters_frame, text="Generate")
89
       generate_button.pack(pady=10)
90
91
       # Создаем текстовое поле для отображения сгенерированного текста.
92
       answer_text = tk.Text(root, wrap="word", font=("Consolas", 10))
93
```

```
94
        answer_text.pack(expand=True, fill="both")
95
       # Добавляем вертикальный скроллбар для текстового поля.
96
       scrollbar = tk.Scrollbar(root, command=answer_text.yview)
97
        scrollbar.pack(side=tk.RIGHT, fill=tk.Y)
        answer_text.config(yscrollcommand=scrollbar.set)
        # Создаем виджеты для задания параметров генерации текста и добавляем команду для кнопки генерации.
       create_widgets(parameters_frame, answer_text, prefix_length_label, initial_prefix_label,
103
        text_length_label, source_filepath_label, generate_button)
104
       # Запускаем главный цикл обработки событий.
105
       root.mainloop()
106
108 # Функция для создания виджетов пользовательского интерфейса, которые будут использоваться для генерации
        текста
109 def create_widgets(parameters_frame, answer_text, prefix_length_label, initial_prefix_label,
        text_length_label, source_filepath_label, generate_button):
        # Обновление параметров генерации текста на основе значений, введенных пользователем в поля.
112
       def update_parameters():
           global prefix_length, initial_prefix, text_length, source_filepath
            # Получаем текущие значения параметров из соответствующих полей.
115
           prefix_length = int(prefix_length_entry.get())
           initial_prefix = initial_prefix_entry.get()
117
           text_length = int(text_length_entry.get())
118
           source_filepath = source_filepath_entry.get()
119
120
           # Обновляем соответствующие метки, отображающие значения параметров.
           prefix_length_label.config(text=f"Prefix Length: {prefix_length}")
           initial_prefix_label.config(text=f"Initial Prefix: {initial_prefix}")
           text_length_label.config(text=f"Text Length: {text_length}")
124
           source_filepath_label.config(text=f"Source File: {source_filepath}")
126
127
        # Функция для генерации и сохранения текста на основе параметров.
128
       def generate_and_save_text():
           # Загружаем текст из файла
129
           corpus = load_text_from_file(source_filepath)
130
            # Предварительно обрабатываем текст
            cleaned_text = preprocess_text(corpus)
134
           # Строим статистику по префиксам
135
           prefix_stats = build_prefix_stats(cleaned_text, prefix_length)
136
137
138
           # Приводим начальный префикс к нижнему регистру
            initial_prefix_lc = initial_prefix.lower()
139
140
            # Генерируем текст на основе полученной статистики по префиксам
141
```

```
142
            generated_text = generate_text(prefix_stats, initial_prefix_lc, text_length)
143
144
            # Проверяем генерированный текст на грамматику и стиль
            corrected_text = grammar_and_style_check(generated_text)
145
            # Записываем результативный текст в файл
147
            with open(answer_filepath, 'w') as f:
                f.write(corrected_text)
149
            # Отображаем сгенерированный и откорректированный текст в соответствующем поле
151
            answer_text.delete("1.0", tk.END)
152
            answer_text.insert("1.0", corrected_text)
153
154
        # Создаем поля ввода для задания параметров генерации текста
        prefix_length_entry = tk.Entry(parameters_frame, width=5)
156
        prefix_length_entry.insert(tk.END, str(prefix_length))
157
        prefix_length_entry.pack(anchor=tk.W, padx=5, pady=5)
158
        prefix_length_entry.bind("<FocusOut>", lambda event: update_parameters())
160
161
        initial_prefix_entry = tk.Entry(parameters_frame, width=20)
        initial_prefix_entry.insert(tk.END, initial_prefix)
162
163
        initial_prefix_entry.pack(anchor=tk.W, padx=5, pady=5)
        initial_prefix_entry.bind("<FocusOut>", lambda event: update_parameters())
164
        text_length_entry = tk.Entry(parameters_frame, width=5)
166
        text_length_entry.insert(tk.END, str(text_length))
167
        text_length_entry.pack(anchor=tk.W, padx=5, pady=5)
168
        text_length_entry.bind("<FocusOut>", lambda event: update_parameters())
170
        source_filepath_entry = tk.Entry(parameters_frame, width=20)
        source_filepath_entry.insert(tk.END, source_filepath)
        source_filepath_entry.pack(anchor=tk.W, padx=5, pady=5)
173
        source_filepath_entry.bind("<FocusOut>", lambda event: update_parameters())
174
175
176
        # Добавляем команду для кнопки генерации текста
177
        generate_button.config(command=generate_and_save_text)
179 # Пути к файлам с исходным и результативным текстом
180 source_filepath = "source.txt"
181 answer_filepath = "answer.txt"
183 # Настройки для генерации текста
184 prefix_length = 1
185 initial_prefix = "because"
186 text_length = 1000
187
188 # Запуск программы
189 if __name__ == "__main__":
       create_gui()
190
```